

# Mantenimiento predictivo con **Redes Neuronales Recurrentes**

Rafa Sanchis Albelda  
Mayo 2019

# Información del problema

Diseñar un sistema capaz de predecir las limpiezas de una serie de moldes.


Con esta información se busca reemplazar un scheduling voraz en tiempo real por un algoritmo que explore más soluciones y permita mejorar el rendimiento de la línea.

- Aprox **1000 moldes** en funcionamiento
  - **12 estados** posibles
  - Aprox **1900 cambios de estado por día**
  - **> 680000 cambios de estado** almacenados
- 
- **15500 limpiezas** (2,5 años)
  - **10500 con información de piezas** fabricadas (1,5 años)


# Información disponible

Disponemos del histórico de estados de los moldes, podemos trabajar prediciendo:

- Horas hasta la próxima limpieza
- Piezas fabricadas hasta la próxima limpieza



Distribución de horas transcurridas entre limpiezas



Distribución de piezas fabricadas entre limpiezas

## Escogemos realizar la predicción de las piezas:

- Menor variabilidad y mejores resultados de la red neuronal.
- Más fácil de integrar en el algoritmo de scheduling.

# Preproceso de los datos

```
id,moldeID,estadoID,fin,next,created_at,updated_at
615382,1085,12,"2019-03-27 11:27:10",615501,"2019-03-27 10:40:20","2019-03-27 11:27:10"
615381,671,0,"2019-03-27 12:30:05",615657,"2019-03-27 10:40:10","2019-03-27 12:30:05"
615380,884,11,"2019-03-27 11:01:20",615436,"2019-03-27 10:40:05","2019-03-27 11:01:20"
615379,897,1,"2019-03-27 13:37:00",615768,"2019-03-27 10:40:02","2019-03-27 13:37:00"
615378,878,12,"2019-03-27 10:39:32",615428,"2019-03-27 10:39:32","2019-03-27 10:58:32"
615377,1175,12,"2019-03-27 11:22:42",615492,"2019-03-27 10:39:12","2019-03-27 11:22:42"
```

Información obtenida de la base de datos

## Preproceso:

- Calcular momento en horas desde instante inicial (sustituye a las fechas)
- Descartar cambios de estado breves (errores)
- Calcular horas transcurridas entre limpiezas
- Eliminar horas correspondientes a fines de semana
- Recuento de piezas fabricadas entre limpiezas
- Descartar estados diferentes a las limpiezas

# Preparación de los sets de entrenamiento y validación

## Selección de la longitud de secuencia

Long. Secuencia	5	7	<b>10</b>	12
Desviación media	8.1024	6.7706	<b>5.4402</b>	5.0979
Test score (MSE)	187.1871	187.0161	<b>179.4253</b>	193.3652

Ventana deslizante para crear las secuencias y el valor a predecir.

piezas	5	14	3	19	20	16	8	26	5	9	17	18	25
horas	48	35	21	70	29	34	25	31	15	26	30	29	46



Aprox 2500 secuencias para entrenamiento.

Aprox 500 secuencias para validación.

Aprox 750 secuencias para test.

Aprox 20 secuencias para test final.


# Topologías de red

## LSTM

Capa	Neuronas	Parámetros
LSTM	128	67584
LSTM	64	49408
LSTM	32	12416
Dense	32	1056
Dropout		
Dense	32	1056
Dropout		
Dense	16	528
Dropout		
Dense	1	17
<b>TOTAL</b>		<b>132065</b>


## GRU

Capa	Neuronas	Parámetros
GRU	256	199680
GRU	128	147840
GRU	64	37056
GRU	32	9312
RepetVector		
TimeDist	1	11
<b>TOTAL</b>		<b>395189</b>



# Entrenamiento


## LSTM



Entrenamiento de la red LSTM

- Mejores resultados.
- Complejo de parametrizar.
- Tendencia al overfitting.
- Muy sensible a cambios en los datos de training.
- Sensible.

## GRU



Entrenamiento de la red GRU

- Parametrización simple.
- Más rápido a igualdad de parámetros entrenables.
- Resultados similares con diferentes ajustes en los datos de training.
- Robustez.

# Parametrización


<b>LSTM</b>	Test 1	Test 2	Test 3	<b>Test 4</b>	Test 5
Total parámetros	129441	31425	548545	<b>132065</b>	132065
Dropout	0.3	0.3	0.5	<b>0.3</b>	0.3
Recurrent Dropout	0.3	0.1	0.2	<b>0.1</b>	0.1
Batch size	100	100	60	<b>100</b>	100
Ajuste train	[1,500]	[1,500]	[1,500]	<b>[1,200]</b>	[1,80]
<b>Results</b>	<b>6.8179</b>	<b>6.8399</b>	<b>6.7402</b>	<b>5.4402</b>	<b>6.4771</b>

<b>GRU</b>	Test 1	<b>Test 2</b>	Test 3	Test 4	Test 5
Total parámetros	23669	<b>395189</b>	1579745	55691	395189
Dropout	0.4	<b>0.2</b>	0	0.2	0.3
Recurrent Dropout	0.4	<b>0.1</b>	0	0.1	0.1
Batch size	100	<b>100</b>	100	100	100
Ajuste train	[1,500]	<b>[1,500]</b>	[1,500]	[1,200]	[1,80]
<b>Results</b>	<b>6.7322</b>	<b>6.7299</b>	<b>6.7463</b>	<b>6.7649</b>	<b>6.7830</b>




# Resultados

## LSTM



Predicciones sobre test

## GRU



Predicciones sobre test

Desviación media de la predicción sobre datos reales	
5.4402	6.7821

# Conclusiones

- Resultados muy mejorables.
- A medida que se cuente con más datos históricos:
  - Será posible mejorar los resultados.
  - Será posible aumentar la longitud de secuencia.
- Los resultados son mejores que una simple media y aplicables al sistema de scheduling del que formará parte.

## Posibles mejoras

- Incorporar información extra para mejorar la predicción:
  - Temperatura del horno final
  - Temperatura ambiente
  - Imágenes de los moldes